

한국에서 실리콘 샘플링은 어디까지 가능한가

두 검증 연구로 본 합성 페르소나에서 응답이력 RAG까지

STUDY 1

Nemotron + KSIS 충실도·분산·편향 진단

STUDY 2

RAPS — 응답이력 RAG 검증과 결정 규칙

이종혁(경희대 미디어학과)

전체 개요

1

여론조사의 위기와 새로운 시도

왜 실리콘 샘플링이 등장했는가

3

선행연구의 지도

긍정론(5) · 회의론(5) · RLHF 분기점

5

STUDY 1 — 합성 페르소나 검증

Nemotron+KSIS, JS 0.132, 4가지 편향

7

두 연구의 통합적 합의

충실도 풍경의 완성

2

실리콘 샘플링이란?

정의·작동 원리·알고리즘적 충실도

4

빈 좌표 → 두 검증 연구로

비영어권 공백 + 차원 분리 부재

6

STUDY 2 — 응답이력 RAG (RAPS)

NBS 16만명 6년, 10개 항목, M2·M3·M4

8

시사점·한계·후속 연구

실무 결정 규칙과 다음 단계

여론조사가 위기에 빠진 시대

측정 비용은 오르고 응답률은 떨어진다

5%대

한국 전화 여론조사의 응답률

온라인 패널 유지비용 증가

신규 이슈는 빠르게 등장

양질의 표본 확보는 점점 어려워짐

여론조사의 핵심은 '얼마나 많은 사람이 어떤 의견을 갖는가'를 측정하는 일이다.

그런데 한국에서 이 측정의 비용은 가팔라지고 있다.

이 간극을 메우려는 새로운 시도가 등장했다.

AI에게 사람인 척 응답하게 하면 어떨까?

→ 실리콘 샘플링 (Silicon Sampling)

LLM에게 특정 인구집단의 정체성을 부여하여
가상 응답자를 만들고, 그 답을 모아
실제 여론의 대용물로 활용하는 접근

실리콘 샘플링이란?

AI에게 페르소나를 부여해 설문에 답하게 하는 방법

정의: 대규모언어모델(LLM)에 특정 인구집단의 정체성을 부여하여 가상의 응답자를 만들고, 그 답변 분포를 실제 인간 응답 분포의 대용물로 사용하려는 접근법

1

페르소나 부여

"당신은 64세 구미 거주
보수 성향 남성입니다"

2

LLM이 답변 생성

그 입장에서
설문 문항에 응답

3

분포로 활용

수천 명을 모아
여론 분포 추정

💡 쉬운 비유: 영화 시뮬레이션처럼 '특정 한국인 같은 AI'를 1,000명 만들어 설문지를 돌리는 것

전통 여론조사 vs 실리콘 샘플링

둘은 무엇이 같고 무엇이 다른가?

구분	전통 여론조사	실리콘 샘플링
응답 주체	실제 사람	LLM이 페르소나를 연기
비용·시간	큼 (전화·온라인 표집 등)	매우 작음 (API 호출만)
윤리적 측면	개인정보·동의 필요	합성 페르소나는 개인정보 없음
강점	진짜 여론, 인과적 해석 가능	빠른 가설 탐색, 사전 점검
약점	표집 편향, 무응답 증가	LLM 편향, 균질화, 시점 고정
적정 용도	공식 조사, 정책 결정 근거	본 조사의 대체보다 보조 도구

실리콘 샘플링은 전통 조사의 '대체'가 아니라 '보조'다 (Sarstedt et al., 2024)

핵심 개념: 알고리즘적 충실도

Argyle et al. (2023)이 명명한 실리콘 샘플링의 평가 기준

알고리즘적 충실도 (Algorithmic Fidelity)

LLM이 인구통계 조건화로 부여된 '특정 부분 모집단'의 응답 분포를 정확히 재현하는 성질

성립하려면 두 조건이 동시에 충족되어야 한다

① 데이터의 문제

LLM의 사전훈련 자료 안에

인구통계와 의견을 잇는 연관 정보가
충분히 압축되어 있어야 한다

예: "호남 70대 농민" 집단의
평균적 정치성향이 학습 데이터에 있어야

② 방법의 문제

적절한 조건화 프롬프트가

압축된 정보를 표면으로
정확히 호출해 낼 수 있어야 한다

예: 페르소나를 '두껍게' 묘사할수록
그 집단의 의견을 더 잘 끌어냄

선행연구 지도 — 긍정론과 회의론의 대립

실리콘 샘플링은 작동하는가, 깨지는가?



긍정론

"AI가 인간 응답을 잘 재현한다"

- **Argyle et al. (2023)**
GPT-3로 ANES 재현 — 테트라코릭 0.9+
- **Aher et al. (2023)**
최후통첩·밀그램 등 고전 실험 재현
- **Park et al. (2024)**
1,052명 인터뷰 디지털 트윈으로 GSS 86%
- **Sun et al. (2024)**
무작위 실리콘 샘플링으로도 유사 분포
- **Moon et al. (2024)**
합성 배경 서사로 ATP 일치율 +18%



회의론

"AI 응답은 분산이 좁고, 부호가 반대로 나올 수 있다"

- **Bisbee et al. (2024)**
분산 절반·회귀계수 부호 32% 반대
- **Santurkar et al. (2023)**
특정 집단으로 의견 쏠림 — 미해소
- **Geng et al. (2024)**
프롬프트 변화에 카멜레온처럼 변동
- **Krumpal (2013)**
민감 주제의 사회적 바람직성 편향(SDB)
- **Chapala et al. (2025)**
최신 LLM에서도 SDB 재확인

Argyle et al. (2023) — "Out of One, Many"

실리콘 샘플링의 원전: GPT-3로 미국 선거 패턴 재현

연구 개요

데이터: 미국 선거조사(ANES) 2012·2016·2020

모델: GPT-3 (RLHF 이전 세대)

조건화: 인구학 정보만 부여 (성별·연령·인종·이념·당파성)

측정: GPT 생성 답변과 실제 ANES 응답의 일치도


결과: 매우 강한 일치

- 양당 투표 선택의 테트라코릭 상관:

2012년 0.90 / 2016년 0.92 / 2020년 0.94

- AI vs 인간 텍스트 구분 불가
(인간 판정 비율 61.2% vs 61.7%)
- 합성 데이터 생성 비용: 단 \$29

AI vs 인간 — 투표 선택 일치도



의의: 인구학 조건화만으로도 거대 모집단의 투표 분포가 매우 정확히 재현됨을 첫 입증. 이를 "algorithmic fidelity"라 명명.

공정론의 확장 — 페르소나 '두께'와 '너비'

Aher (2023) · Park (2024) · Sun (2024) · Moon (2024)

Park et al. (2024) — Digital Twin (깊이)

1,052명 × 2시간 심층 인터뷰 → 디지털 트윈

- 인구학만: 정규화 정확도 0.74
- 인터뷰 단독: 0.83 (+9%p)
- 인터뷰 + 설문: 0.86 (+12%p)

→ 인터뷰가 인구학 태그보다 충실도 향상
→ 비용 한계로 1,052명에 묶임

Sun et al. (2024) — 무작위 실리콘 (너비)

GPT-3.5에 인구통계 분포만 주입
→ ANES와 유사한 응답 분포 산출

- 깊이를 포기하고 너비를 극대화
- 영역에 따라 큰 격차 — 사전훈련에
자료가 풍부한 영역에서 강한 충실도
- 새 이슈에는 검증 부족 (한계)

Aher et al. (2023) — 고전 실험 재현

LLM이 사회과학 고전 실험을 정성적으로 재현

- 최후통첩 게임 (경제학)
- 가든 패스 문장 (심리언어학)
- 밀그램 복종 실험 (사회심리학)

→ 인간 행동 패턴을 LLM이 '연기' 가능

Moon et al. (2024) — Backstory Anthology

LLM이 합성한 가상의 배경 서사를 페르소나로

- 인터뷰 수집 비용 우회
- 미국 ATP 패널 응답 일치율 최대 +18%
- 그러나 합성 서사 자체의 검증 필요

→ 합성 자원의 새로운 가능성

Bisbee et al. (2024) — 분산 축소의 정량 비판

"Synthetic Replacements" — 회의론의 대표 논거

동일한 GPT 계열인데 Argyle은 충실도가 높았고, Bisbee는 회의적 결과를 냈다. 왜 그럴까?

① 분산 축소 (Homogenization)

0.5×

실측의 절반

합성 응답의 표준편차가 실측의 절반 수준
(예: 31.4 → 16.1).
분산이 좁아져 결론에 필요한 표본 수가
비현실적으로 작게 추정됨.

② 추론적 타당성 실패

48%

회귀계수 어긋남

합성 자료 회귀계수의 48%가
실측과 통계적으로 다름.
그 중 32%는 부호까지 반대.
변수 관계 자체가 빗나감.

③ 재현성 위험

3개월

분포 변동 주기

같은 프롬프트인데도 모델 업데이트 후
분포가 달라짐.
연구 재현성이 모델 버전에 종속됨.

핵심: 합성 응답이 정치적 적대를 0.5~1 SD 차갑게 그려 — 사회를 실재보다 적대적으로 만든다

왜 같은 GPT인데 결과가 다를까?

결정적 변수 RLHF + 사회적 바람직성 편향(SDB)

RLHF (Reinforcement Learning from Human Feedback)

인간 피드백으로 모델을 "사회적으로 바람직한 답"으로 정렬하는 학습 단계

Argyle (GPT-3, RLHF 이전): 충실도 ↑ vs Bisbee (GPT-3.5, RLHF 적용): 균질화·갈등 과장

→ RLHF 이후 모델은 노골적 부정·극단 응답을 피하고 **온건한 중도**로 끌어당김

Krumpal (2013) — SDB 종합

Quality & Quantity 게재

인종·이민·성·동성결혼 같은 민감 주제에서
인간 응답자조차 진실보다 '사회적으로 옳은'
방향으로 답하는 경향 — 사회적 바람직성 편향.

Chapala et al. (2025) + Santurkar (2023)

최신 LLM에서도 SDB 재확인

Llama-3.1 / GPT-4.1-mini 모두 SDB 일관 발견.
안전 정렬 학습으로 인해 LLM은 SDB를
인간보다 더 강하게 드러냄. 조향해도 미해소.

선행연구가 남긴 빈 좌표

두 연구가 매우려는 공백

공백 ① 비영어권 검증 부재

검증 자료 거의 전부가 미국(ANES·GSS·CES) 또는 글로벌 단일 시점 자료에 집중.
→ 사전훈련의 인구학-의견 연관이 한국에서 성립하는지 검증되지 않음.

공백 ② 종단성·차원 분리의 부재

거의 모든 검증이 단면 자료.
총실도의 '수준·분산·방향'을 단일 시스템에서 함께 관찰한 사례 드물.
→ 시점 이동·새로운 이슈에 대한 외삽 능력 미검증.

총실도는 단일한 양이 아니라 최소 세 차원으로 분해된다

① 수준 (Level)

분포의 전체 모양이
실측과 얼마나 닮았는가?

② 분산 (Spread)

그 닮음이 다양성을
희생한 결과는 아닌가?

③ 방향 (Direction)

어긋남이 무작위인가,
한 쪽으로 치우쳤는가?

두 검증 연구

공백을 메우는 두 갈래의 접근

선행연구의 두 극단

Argyle · Sun

너비 ↑ / 깊이 ↓

인구학 태그만으로
많은 페르소나 생성

Park (2024)

깊이 ↑ / 너비 ↓

2시간 인터뷰로
1,052명 디지털 트윈

두 극단 사이의 '중간 좌표'를 다른 방식으로 시도

STUDY 1 — 합성 페르소나 + 통계적 보강

데이터: Nemotron 합성 페르소나 + KSIS 2025

접근: 인구학 → 정치성향 조건부 모델로 보강

검증: 12개 미학습 항목, 평균 JS 0.132

기여 영역: 비영어권 첫 정량 검증 + 균질화·편향 식별

STUDY 2 — 응답이력 RAG (RAPS)

데이터: NBS 16만 7천명 × 6년 종단 응답이력

접근: KR-SBERT 검색 + RAG로 외부 기억 활용

검증: 10개 항목, 우수 7 (KL 0.092) + 한계 3

기여 영역: '시간'이라는 축 추가 + 실패 메커니즘 분류

PART 5

STUDY 1

한국형 실리콘 샘플링의 가능성과 한계: 합성 페르소나와 사회통합실태조사를 결합한 12개 미학습 항목의 충실도·분산·편향 진단

Nemotron-Personas-Korea × 사회통합실태조사(KSIS) 2025

Study 1의 5가지 연구문제

수준 → 분산 → 유형 → 척도 → 방향의 논리적 위계




검증적 RQ1·RQ2: Argyle·Bisbee 등 영어권 결과를 한국 맥락에서 **재확인**.

기여적 RQ3·RQ4·RQ5: 동일 시스템 안에서 **처음으로 비교**. Study 1의 새로운 학술적 기여 지점.


STUDY 1 · 구현 과정 흐름도

Nemotron 합성 페르소나 × KSIS 조건부 모델 보강 — 12개 미학습 설문 응답까지



STUDY 1 · 평가 과정 흐름도

5개 연구문제별 평가 지표와 결과 — 단일 시스템에서 동시 관찰



Study 1의 두 데이터 — 합성 페르소나 + 실측 정답

Nemotron(NVIDIA) × KSIS(한국행정연구원)

Nemotron-Personas-Korea

NVIDIA, 합성 한국인 페르소나

규모: 약 100만 명

생성 원리: 통계청(KOSIS) 등 공개 통계 결합분포 보존

구조화 필드: 성별·연령·시도·학력·직업·혼인·주거 등

서사 필드: 인물 요약·직업·취미 등 → LLM이 입체적 몰입

한계: 정치성향 없음 → KSIS로 보완 필요

사회통합실태조사 (KSIS) 2025

한국행정연구원, 실응답 자료

규모: 실응답 8,305명 × 292개 변수

두 가지 역할:

① 조건부 모델의 학습 데이터

인구학 ↔ 정치성향 실제 관계

② 충실도 검증의 정답(ground truth)

12개 미학습 항목 실측 분포

페르소나는 어떻게 생겼나? — 실제 사례

방길동 씨, 64세 보수 성향 남성

① 구조화 필드

성별: 남자

연령: 64세

거주: 경상북도 구미

혼인: 배우자 있음

직업: 기타 / 주거: 아파트

② 보간된 정치성향 (조건부 모델 출력)

이념: 7점 (보수 성향)

지지정당: 있음

종교: 무종교

2025 대선 투표: 참여

③ Nemotron 서사 필드

"방길동 씨는 구미 산단의 정밀함을 몸에 익힌 실용주의자로, 꼼꼼한 자기관리와 사회적 활달함 뒤에 예민한 불안감을 숨기고 살아가는 60대 남성입니다..."

💡 ①+②+③을 자연어로 묶은 프롬프트로 LLM이 "이 사람의 입장에서" 12개 설문에 응답

Study 1의 핵심 아이디어 — 조건부 확률 모델

확률 분포에서 추출 → 같은 인구학 페르소나도 매번 다른 정치성향

입력 (7개 인구학)

- 성별
- 연령
- 권역
- 학력
- 혼인 상태
- 직업
- 주거 형태

다항 로지스틱 회귀
× 10개 타깃 별도 학습

출력 (10개 정치·사회)

- 이념성향 (0~10)
- 지지정당 유무
- 종교
- 가구소득 5분위
- 정치 관심도
- 2025 대선 투표
- 외집단 감정온도 등

🔑 핵심: 모델 출력은 단일 예측이 아니라 "확률 분포"

"서울 32세 여성·전문대졸·사무직" 입력 → "이 사람은 진보다" ❌ vs "각 이념에 어느 정도 확률" ✅

→ 이 분포에서 무작위 추출 → 같은 인구학 페르소나도 매번 다른 정치성향

Study 1 · 충실도 검증 12개 항목 (KSIS 2025)

행동·사실형(미디어) 8개 + 규범·태도형(사회) 4개 — 조건부 모델 학습에 사용하지 않은 hold-out 항목

행동·사실형 · 미디어 이용 빈도 (8개)		
문항(공통) 귀하는 평소 정보를 얻기 위해 다음과 같은 매체를 얼마나 자주 이용하십니까? ※ 신문·TV·라디오는 인터넷 사이트 직접 접속한 경우도 포함합니다.		
보기(공통) ① 전혀 이용하지 않는다 ② 몇 개월에 한 번 ③ 한 달에 1~3일 ④ 일주일에 1~2일 ⑤ 일주일에 3~4일 ⑥ 일주일에 5~6일 ⑦ 매일		
번호	항목 (하위문항)	KSIS 코드
①	신문 (인터넷 사이트 접속 포함)	q22_1
②	TV (인터넷 사이트 접속 포함)	q22_2
③	라디오 (인터넷 사이트 접속 포함)	q22_3
④	메신저 (카카오톡·인스타DM·텔레그램·라인 등)	q22_4
⑤	SNS (인스타그램·X(트위터)·페이스북 등)	q22_5
⑥	인터넷 포털사이트·블로그·카페 등	q22_6
⑦	온라인 동영상 매체 (유튜브 등)	q22_7
⑧	생성형 AI (Chat GPT·Gemini 등)	q22_8

척도: 1~7 점 (7점 빈도형, 전 항목 동일)

규범·태도형 · 사회 태도 인식 (4개)				
항목	코드	문항 원문	보기	척도
① 외국인 수용 동의	q41	귀하는 외국인을 우리나라 국민으로 받아들이는 것에 대하여 어떻게 생각하십니까?	0 (전혀 동의하지 않는다) ~ 10 (매우 동의한다)	0~10 11점
② 성소수자 수용 거리	q42_5	귀하는 다음과 같은 사람들을 어느 정도 관계까지 받아들일 수 있습니까? — 성적 소수자	① 받아들일 수 없음 ② 이웃 ③ 직장 동료 ④ 절친한 친구 ⑤ 배우자	1~5 5점
③ 세대 갈등 인식	q46_6	귀하는 현재 우리 사회에서 다음의 갈등 정도가 어느 정도 심하다고 생각하십니까? — 고령층과 젊은층 간의 갈등	① 전혀 심하지 않다 ② 별로 심하지 않다 ③ 약간 심하다 ④ 매우 심하다	1~4 4점
④ 검찰 신뢰	q31_4	귀하는 다음 기관들이 맡은 일을 수행하는 것에 대해서 얼마나 신뢰하십니까? — 검찰	① 전혀 신뢰하지 않는다 ② 별로 신뢰하지 않는다 ③ 약간 신뢰한다 ④ 매우 신뢰한다	1~4 4점
설계 의도: 미디어 8개는 척도 통일(유형 효과 검증) · 사회 4개는 척도 혼재 4·5·11점 (척도 길이 효과 검증)				

Study 1 결과 ① 충실도의 수준 (RQ1)

12개 미학습 항목 평균 JS = 0.132 — "강한 일치 ~ 유사" 대역


평균 JS

0.132

강한 일치 + 유사 경계

12개 중 11개 항목이 JS < 0.20

JS 구간별 항목 수



☑ RQ1 결론: 비영어권·한국에서도 실리콘 샘플링이 분포 단위에서 유의미하게 작동 — Argyle(2023) 한국 재확인

Study 1 결과 ② 균질화 (RQ2)

Bisbee(2024)의 분산 축소가 한국에서도 명확히 재현

SD비

0.72

시물 표준편차 = 실측의 72%


12개 중

10개

항목에서 분산 축소 발생

극단 사례: 메신저 이용 빈도

SD비 0.18 · 엔트로피비 0.08 — 거의 모든 다양성 소멸




LLM은 "한국인은 카카오톡을 당연히 매일 쓴다"는 강한 사전 도식을 가짐 → 인구학에 따른 빈도 다양성 소실

Study 1 결과 ③ 두 가지 발견 (RQ3, RQ4)

예상했던 두 효과가 모두 부정됨

RQ3 — 문항 유형 효과

행동·사실형(미디어) vs 규범·태도형(사회) 충실도 차이?




차이 없는 것으로 판단

격차 0.006 — 사실상 동등.
오히려 규범·태도형이 약간 더 정확.

RQ4 — 척도 길이 효과

긴 척도일수록 충실도가 떨어지는가?



차이 없는 것으로 판단

11점도 0.133 — 7점·4점과 사실상 동등.
척도 길이는 충실도의 결정 변수가 아님.

Study 1 결과 ④ 어긋남에는 방향이 있다 (RQ5)

LLM 응답이 일관된 4가지 방향으로 편향됨

① 온건한 긍정 편향

+1.12점

외국인 수용 평균점

실측 5.47점 → 시물 6.59점
부정적 응답이 거의 사라지고 우호적 중도로 수렴

② 사회 갈등 과장

+39.3%p

세대갈등 "매우 심각"

실측 10.6% → 시물 49.9%
LLM이 한국 사회의 갈등을 실측보다 훨씬 심각하게 인식

③ 사회적 바람직성

-47.4%p

성소수자 "받아들일 수 없다"

실측 48.3% → 시물 0.9%
노골적 거부를 회피하고 우호적 중도로 이동

④ 디지털 고정관념

-2.21점

TV 이용 평균점

실측 6.17점 → 시물 3.96점
메신저·포털 과대 / TV·유튜브·생성AI는 과소평가

💡 4가지는 별개가 아니라 RLHF 정렬과 사전 도식 내면화의 서로 다른 표출

Study 1 — 페르소나 사례로 본 균질화

이념이 정반대인데 외국인 수용에 같은 7점을 답함

매우 진보 페르소나 (이념 1점)

충남 천안 거주
20세 남성 청년

(이념 1=매우 진보)

LLM 응답: 7점

"한국 사회에 기여하고 잘 적응하려는 외국인이라면 긍정적으로 받아들이야..."

매우 보수 페르소나 (이념 9점)

경남 창원 거주
53세 여성 생산관리자

(이념 9=매우 보수)

LLM 응답: 7점

"우리 경제에도 도움이 되는 부분이 있다고 생각합니다. 다만 우리 문화와 정서에 잘 적응하고 함께 살아갈 수 있도록..."

💡 이념이 정반대인 두 페르소나가 같은 7점, "다만 ~ 적응한다면"이라는 동일한 수사 구조까지 사용

→ LLM이 이념 방향성은 미세하게 반영하되, 전체를 "우호적 중도"로 강하게 끌어당기는 균질화·긍정 편향이 동시 작용

Study 1 종합 — 5가지 발견과 그 의미

비영어권 첫 정량 검증의 결론

RQ	주제	주요 결과	선행연구 관계
RQ1	수준	평균 JS 0.132 — 분포 단위에서 유의미한 작동	Argyle(2023) 한국 재확인
RQ2	분산	SD비 0.72 — 12개 중 10개에서 균질화	Bisbee(2024) 재현
RQ3	유형	행동·사실 0.134 ≈ 규범·태도 0.127	단일 시스템 첫 비교
RQ4	척도	4·5·7·11점 대체로 동등	단일 시스템 첫 비교
RQ5	방향	긍정·갈등 과장·SDB·디지털 4가지 편향 식별	메커니즘 식별

🌀 Study 1의 통합 메시지

Argyle 긍정론과 Bisbee 회의론은 "모순"이 아니라 "같은 그림의 두 얼굴". 실리콘 샘플링은 평균 분포는 잘 재현하지만, 그 재현은 "분산을 잃고 사회적으로 바람직한 방향으로 수렴한 채" 잘 된다는 구조적 형태를 가진다.

그러나 Study 1은 **단면 자료와 합성 페르소나라는 두 한계**를 그대로 안고 있다 → Study 2로 이어진다.

Study 1이 남긴 두 한계 → Study 2의 진입

단면 자료와 합성 페르소나를 넘어서

Study 1의 한계

① 단면 자료의 한계

KSIS 2025 한 시점만 사용.

정권 교체·신규 이슈 외삽 능력 미검증.

② 합성 페르소나의 한계

Nemotron은 통계적으로 그럴듯한 '가상'

한국인 — 실재 응답이 남긴 가치관의 흔적은 없다.

→ 무엇이 필요한가?

실재 응답자가 여러 시점에 걸쳐 남긴

객관식 응답이력이라는 세 번째 자원.

Study 2의 진입 — RAPS

Response-history Augmented Persona Survey

핵심 자원: NBS 종단 자료

- 16만 7천여 명 실재 응답자
- 6년에 걸친 응답이력
- 1,200+ 고유 문항

핵심 방법: 검색증강생성(RAG)

KR-SBERT로 과거 응답을 '외부 기억'으로 LLM에 검색·주입

→ Park '깊이', Sun '너비'가 아닌

'시간'이라는 제3의 축.

PART 6

STUDY 2

인터뷰 없는 '실리콘 샘플링(*silicon sampling*)'은 가능한가: 응답이력 기반 페르소나 설문조사(*RAPS, Response-history Augmented Persona Survey*) 시스템 제안과 검증

전국지표조사(*NBS*) 6년 응답이력 × *KR-SBERT* × *Gemini*

Study 2의 핵심 아이디어 — 제3의 축, '시간'

Park '깊이' + Sun '너비' + RAPS '시간'

선행 두 접근의 trade-off와 RAPS의 새 좌표

Park (2024)

깊이 (Depth)

2시간 인터뷰 → 1,052명
인터뷰 비용 ↑↑
비서구 확장 어려움

Sun (2024) · Argyle (2023)

너비 (Breadth)

인구통계 분포만 → 많은 페르소나
개인 내러티브 없음
새 이슈에는 검증 부족

RAPS (Study 2)

시간 (Time)

16만명 × 6년 응답이력
인터뷰 없이 객관식 깊이 확보
시점 이동·신규 이슈 검증 가능

RAPS (Response-history Augmented Persona Survey)

한 응답자의 **과거 객관식 답변**을 검색해 페르소나 컨텍스트로 결합 — RAG 기반 실리콘 샘플링

Park가 "인간의 깊이"를 인터뷰로 잡았다면, RAPS는 "**인간의 너비와 시간**"을 응답이력으로 잡는다.

→ 인터뷰 비용 없이 의미 있는 충실도가 가능한 새로운 좌표.

Study 2의 6가지 연구문제

작동 영역 → 메커니즘 → 비교 → 결정 규칙으로 이어지는 단계적 검증

RQ1 작동 영역

10개 항목 전체 충실도
지도는 어떻게 그려지는가?

RQ2 우수 메커니즘

충실도 우수 항목에서
무엇이 작동하는가?

RQ3 실패 메커니즘

한계 항목은 어떻게
어떤 메커니즘으로 깨지는가?

RQ4 방식 비교

3가지 샘플링 방식 간
충실도는 어떻게 다른가?

RQ5 유형 차별화

설문항목 유형에 따라
충실도가 어떻게 다른가?

RQ6 결정 규칙

새 질문이 입력되면
어떤 방식을 선택해야 하는가?


STUDY 2 · 구현 과정 흐름도 (RAPS 파이프라인)

NBS 종단 응답이력 × KR-SBERT 검색증강 — 4단계 + 3가지 샘플링 방식


외부 기억 (External Memory)

NBS 1-164회차 · 166,721명 · 1,219개 고유 문항 · 6년 종단 (2020-2025)

✉ 새 질문 입력 (Query)



3가지 샘플링 방식 (입력 변수만 다름)



결과: 각 페르소나의 응답 → 보기 매핑 → 응답 분포 산출 / 10항목 × 3방식 × 1,000명 = 30,000회 호출

STUDY 2 · 평가 과정 흐름도

10개 hold-out 항목 × 3방식 × 1,000명 = 30,000 호출 → 6개 RQ 단계적 평가

실측 (Ground Truth)

NBS 165-171회차 공식 통계표 · 10개 검증 항목 (S 1 + A 4 + Frontier 5)

시뮬레이션 (RAPS 출력)

10항목 × 3방식 × 1,000명 = 30,000회 호출 결과 분포

KL · JS 발산 측정 (분포 차이 정량화)

RQ1 작동 영역

Actual KL ≤ 0.2 기준

우수 7 / 한계 3

10개가 깨끗하게 분리
0.021 ~ 0.877

RQ2 우수 메커니즘

검색 정합성 추적

평균 KL 0.092

KR-SBERT가 정합한
과거 문항 회수 → 결합

RQ3 실패 메커니즘

이념별 응답 분산

3 메커니즘 분리

M2 시점표류 (9.6%p)
M3 LLM사전 (24.4%p)
M4 이념과잉 (88.6%p)

RQ4 방식 비교

평균 KL 비교

Actual 6.6× 개선

Demographic 0.612 → Actual 0.092
(Synthetic 0.521)

RQ5 유형 차별화

유형 × 방식 평균 KL

Frontier 10.2×

S 7.9× / A 4.6×
사전훈련 약한 영역에서 RAG 가치 최대

RQ6 결정 규칙

방식 × 유형 교호작용

4단계 분기

정권교체→최근 가중, 미래예측→Demo 병행
사전강→Actual+Synth, 그라데이션→temp 하향

종합: Actual 평균 KL 0.092 (강한 일치) + 실패 메커니즘 3분류 + 실무 결정 규칙 도출 → "쓸 수 있나 없나"가 아니라 "어떻게 보정해서 쓸까"

Study 2의 자료 — NBS 종단 응답이력

전국지표조사 1~164회차 누적 자원

NBS 자원

166,721명

누적 응답자 (1~164회차)

6년 종단

2020 ~ 2025

1,219개 문항

통합 wide table 기준 고유 문항

응답자 1인당 평균 응답 20~30개
— '알지만 종단적인 깊이'

NBS 자원의 결정적 특성

① 희소(sparse) 응답

1인당 평균 20~30개 문항만 응답.
→ 한 응답자는 "부분만 알려진 사람"

② 회차마다 새로운 이슈 추가

정권 교체, 12·3 비상계엄, 초심야배송 등
→ 신규 이슈에 대한 외삽 능력 검증 가능

③ 핵심 가치관 변수 확보

거의 모든 응답자에 대해 정치성향·이념·
지지정당·정당호감도·계층의식 확보

Study 2의 3가지 샘플링 방식

같은 1,000명 페르소나에 입력 변수만 달리해 비교

① Demographic (baseline)

입력 변수

성별 · 연령 · 지역 · 직업
인구학 4개 변수만

패러다임

Argyle (2023) · Sun (2024)
인구통계 조건화에 해당

프롬프트 평균 267자

② NBS-Actual (개인 수준 검색)

입력 변수

인구학 4개 +
해당 페르소나의 핵심 컬럼 + 검색 결과

패러다임

Park (2024) · Moon (2024)
계열의 개인 수준 충실도

프롬프트 평균 461자

③ NBS-Synthetic (집계 수준 분포)

입력 변수

인구학 4개 +
셀의 핵심 5문항 분포 통계

패러다임

Sun (2024) 무작위 실리콘을
다변수 분포로 강화한 변형

프롬프트 평균 926자

RAPS의 작동 파이프라인

새 질문 입력부터 응답 분포 산출까지의 4단계



검증 호출 규모

10개 항목 × 3개 샘플링 방식 × 1,000명 = **30,000회 LLM 호출** / 소요 시간: **약 33분**

🔑 **핵심 작동 원리:** 검색된 상위 5개는 "응답자 필터"가 아니라 "각 페르소나 행에서 어느 컬럼을 조회할지 결정하는 컬럼 선택자"

Study 2 · 검증 항목 10개 (NBS 165~171회차)


핵심 정치 항목(S) · 정책 태도 항목(A) · 신생 이슈 항목(Frontier) — 우수 7개 + 한계 3개

유형	NBS 코드	약칭	문항 원문 (요약)	보기	결과
Standard 고정: 핵심 정치 관련 — 매 회차 반복되는 핵심 정치 지표					
S	165-1	이재명 국정운영 평가	이재명 대통령이 대통령으로서 일을 잘하고 있다고 생각하십니까?	① 매우 잘하고 있다 ② 잘하는 편이다 ③ 잘못하는 편이다 ④ 매우 잘못하고 있다 ⑤ 모름/무응답	✗ 한계
S	165-3	정당 지지도	현재 지지하는 정당이 있다면 어느 정당입니까?	① 더불어민주당 ② 국민의힘 ③ 조국혁신당 ④ 개혁신당 ⑤ 진보당 ⑥ 기타 ⑦ 없음/유보	☑ 우수
Ad-hoc 현안: 당시 정책 관련 — 특정 정책에 대한 태도·찬반 (학습 자료 내 풍부한 신호 예상)					
A	165-7	양극화 — 빈부 격차	현재 우리 사회의 빈부 간 양극화 수준이 어느 정도 심각하다고 생각하십니까?	① 매우 심각 ② 심각한 편 ③ 심각하지 않은 편 ④ 전혀 심각하지 않음 ⑤ 모름/무응답	☑ 우수
A	165-11	주 4.5일제 찬반	정부가 추진 중인 주 4.5일 근무제에 대해 어떻게 생각하십니까?	① 찬성한다 ② 반대한다 ③ 모름/무응답	☑ 우수
A	167-10	주택 세제 개편 찬반	주택 거래세를 낮추고 보유세를 높이는 방향의 부동산 세제 개편에 찬성하십니까?	① 찬성한다 ② 반대한다 ③ 모름/무응답	☑ 우수
A	171-9-5	국가기관 신뢰 — 검찰	다음 국가기관을 어느 정도 신뢰하십니까? — 검찰	① 매우 신뢰 ② 신뢰하는 편 ③ 신뢰하지 않는 편 ④ 전혀 신뢰하지 않음 ⑤ 모름/무응답	☑ 우수
Frontier 신규 – 새로운 이슈 관련 — SDB(사회적 바람직성 편향)가 강하면서 학습 자료에 직접 포함되지 않은 신규 이슈					
Fr	166-6	추석 대통령 예능 출연 평가	이재명 대통령의 추석 연휴 예능 프로그램 출연을 어떻게 평가하십니까?	① 긍정적으로 평가한다 ② 부정적으로 평가한다 ③ 모름/무응답	☑ 우수
Fr	170-7	12·3 비상계엄 내란 해당 여부	2024년 12월 3일 비상계엄 선포가 내란에 해당한다고 생각하십니까?	① 해당한다 ② 해당하지 않는다 ③ 모름/무응답	☑ 우수
Fr	170-9	개인정보 유출 징벌적 손해배상	기업·기관의 개인정보 유출에 대해 징벌적 손해배상 제도 도입에 찬성하십니까?	① 매우 찬성 ② 대체로 찬성 ③ 대체로 반대 ④ 매우 반대 ⑤ 모름/무응답	✗ 한계
Fr	168-6	자정~오전5시 초심야 배송 제한	노동자 보호를 위해 자정~오전5시 초심야 배송을 제한하는 것에 찬성하십니까?	① 노동권 제한이 우선이다 ② 소비자 편의 유지가 우선이다 ③ 모름/무응답	✗ 한계

※ 보기 원문은 NBS 공식 통계표 기준 · 일부 항목은 축약 표기 · 우수 기준: NBS-Actual 샘플링 방식 $KL \leq 0.2$

Study 2 결과 ① 10개 항목 작동 영역 지도 (RQ1)

NBS-Actual 기준 $KL \leq 0.2$ 를 경계로 우수 7개 vs 한계 3개 깨끗하게 분리



핵심 관찰

☑ 우수 7개 ($KL \leq 0.2$)

평균 KL 0.092 — 강한 일치
12·3 비상계엄·예능 출연 등
Frontier(SDB+신규) 영역도 포함
→ 영역 횡단적 작동

⚠ 한계 3개 ($KL > 0.4$)

KL 0.46 ~ 0.88 — 뚜렷이 다름

신정부 평가 + 신규 이슈 2개
→ 시점 외삽과 신규성이
RAPS 한계의 주된 경계

M2/M3/M4 세 메커니즘으로
분리 관찰 가능

Study 2 결과 ② 우수 7개의 작동 메커니즘 (RQ2)

KR-SBERT가 추출한 의미적으로 정합한 과거 문항이 충실도를 끌어올림

우수 7개
평균 KL

0.092

강한 일치 영역

Demographic 대비

6.6배

개선 (0.612 → 0.092)

KR-SBERT의 검색 정합성 — 4가지 사례

정당지지도 (165-3)

코사인 0.81~0.82

동일 주제 정당지지 문항 5회차에 걸쳐 추출 — 가장 명확한 사례

양극화 (165-7)

코사인 0.7+

동일 주제 양극화 + 정치 갈등 인식 + 임금 수준 인식 결합

주 4.5일제 (165-11)

코사인 0.6+

주 52→69시간 유연화, 정년 연장 등 노동시간 관련 문항 추출

12·3 비상계엄 (170-7)

코사인 0.48~0.56

직접 대응 없지만 3대 특검·윤석열 구속 등 "후속 사건" 문항으로 의미 연결

Study 2 결과 ③ 한계 3개의 세 가지 실패 메커니즘 (RQ3)

동일 인프라가 적용되었는데 "왜" 깨지는가 — $M2 \cdot M3 \cdot M4$

M2

Temporal drift

시점 표류

사례 항목

165-1 국정운영

9.6%p

이념별 분산 (차별화 실종)

Actual이 부호까지 반대 산출
전 이념대가 모두 부정으로 쏠림

M3

LLM prior

LLM 사전 도식

사례 항목

168-6 초심야배송

24.4%p

이념별 분산 (한쪽 쏠림)

모든 이념대에서 노동 지지 강하게 나타남
RAG 정도와 무관한 모델 사전학습으로 판단

M4

Ideology over-use

이념 과잉 활용

사례 항목

170-9 개인정보 손배

88.6%p

이념별 분산 (이항 양극화)

적절한 그라데이션 깨짐

💡 핵심: 한계 3개의 실패 메커니즘이 "이념별 응답률 분산"이라는 단일 지표로 깨끗하게 분리됨

실패 메커니즘 — 사례로 들여다보기

Bisbee(2024) 시간적 불안정성 · Santurkar(2023) 의견 쓸림 · Chapala(2025) SDB가 분리되어 식별됨

M2 시점 표류

165-1 국정운영 평가

실측 vs 시뮬

실측: 긍정 57% > 부정 33%

시뮬: 긍정 7% < **부정 77%**

→ **정반대 부호!**

원인: 학습자료(1~164)는 윤석열 정부기 / 검증(165)은 이재명 신정부 직후 → 정권 교체로 '보수' 신호가 신정부에선 부정 방향으로 작용

보정: 최근 회차 가중 검색

M3 LLM 사전 도식

168-6 초심야배송 제한

실측 vs 시뮬

실측: 노동권 45% ≈ 소비자 49%

시뮬: 모든 이념대에서

노동권 89.6~100% 쓸림!

→ **분포 평탄화**

원인: LLM의 사전 도식 — '노동 약자 보호'가 개인 검색을 압도. Demographic-Synthetic도 같은 쓸림 → 모델 자체 사전의 강한 작용

보정: Actual + Synthetic 혼합

M4 이념 과잉 활용

170-9 개인정보 손해배상

이념별 '매우 찬성' 응답률

매우 진보: **88.6%**

진보: 44.5%

중도: 2.1%

보수·매우 보수: **0%**

→ **이향 양극화!**


원인: LLM이 '기업 처벌 = 진보' 도식을 이향으로 과 적용. 실측의 '중도·보수의 부분 찬성'을 흡수해버림

보정: temperature 하향 + 프롬프트

Study 2 결과 ④ 3가지 샘플링 방식의 정량 비교 (RQ4)

우수 7개 항목에서 NBS-Actual 일관 우승 — 개인 수준 검색의 우위

3가지 샘플링 방식 — 우수 7개 평균 KL



핵심 관찰

① NBS-Actual 일관된 우승

우수 7개 모든 항목에서 우승
개인 수준 검색의 우위가
단일 시스템 안에서 입증됨

② Demographic $\approx$ Synthetic

셀 통계만 의인화하는 것은 RAG에 본질적으로 약함
(분포 통계 < 실제 응답이력)


③ Frontier에서 가치 $\uparrow \uparrow$

Demographic이 가장 약한 영역에서 RAG 개선 배율 최대
→ 대통령 예능 14.4배 개선

Study 2 결과 ⑤⑥ 설문 유형별 차별화 + 결정 규칙 (RQ5·RQ6)

Frontier에서 RAG 가치 최대 — 실무 적용 의사결정 분기

RQ5 — 유형별 평균 KL (Demographic vs Actual)



Frontier 영역에서 RAG의 가치 최대!

S: 7.9× | A: 4.6× | **Frontier: 10.2× 개선**
→ 사전훈련에 정보가 적은 영역에서 RAG가 결정적

RQ6 — 새 NBS 질문 입력 시 결정 규칙

① 정권 교체 직후 정치 평가인가?

→ 최근 회차 가중 검색 (M2 회피)

② 미래 예측·약한 신호 질문인가?

→ Demographic 병행 (RAG 잡음 회피)

③ 사회 합의 이슈 (그라데이션)?

→ temperature 하향 (M4 회피)

④ LLM 사전 강한 영역(노동·환경)?

→ Actual + Synthetic 혼합 (M3 회피)

⑤ 위 4개 모두 통과한 일반 영역?

→ NBS-Actual 단독 (평균 6.6배 개선)

PART 7

두 연구의 통합적 함의

*Study 1 + Study 2가 함께 그리는 한국 실리콘 샘플링의 풍경
무엇이 작동하고, 어디서 깨지며, 어떻게 보정해야 하는가*

두 연구의 통합 비교

같은 LLM 시대를 서로 다른 자원으로 들여다본 두 시도

차원	STUDY 1 (Nemotron + KSIS)	STUDY 2 (RAPS / NBS RAG)
핵심 자원	Nemotron 합성 페르소나 + KSIS 단면	NBS 16만명 6년 종단 응답이력
페르소나 구성	인구학 + 조건부 모델로 정치성향 보간	인구학 + KR-SBERT로 과거 응답 검색
검증 자료	KSIS 12개 미학습 항목 (단면)	NBS 165~171회차 10개 항목 (시점 외삽)
충실도 지표	JS 발산 (척도 다른 항목 비교)	KL + JS (Actual 우승 기준 0.2)
주요 결과	평균 JS 0.132 + SD비 0.72 + 4가지 편향	우수 7 (KL 0.092) + 한계 3 (M2/M3/M4)
핵심 기여	비영어권 첫 정량 검증 + 충실도 세 차원 분리	시간이라는 제3의 축 + 실패 메커니즘 분류
한계	단면 자료 / 합성 페르소나의 한계	단일 LLM / 권역 분포 / 작은 셀 불안정

💡 Study 1이 "문제의 지형도"를 정량화했다면, Study 2는 "보정의 출발점"을 제시한다

통합 실무 지침 — 어디까지 쓸 수 있나?

두 연구가 함께 원하는 실리콘 샘플링의 적정 용도

사용해도 좋은 용도

설문 사전 점검 / 가설 탐색

Study 1: 평균 분포 모양 파악

Study 2: NBS-Actual 강한 일치 영역

정책 시뮬레이션 (조건부)

Study 2 RQ6 결정 규칙 준수 하에서

세대·지역·이념별 반응 예측

타깃 마케팅·UX 페르소나

유형 S와 A에 한정해 활용

연구 도구 사전 검증

단독 사용 위험한 용도

공식 여론조사 대체

Study 1: 분산 좁아 잘못된 자신감

Study 2: 한계 3개 영역 KL 0.5+

민감 태도 절대 수준 추정

성소수자·외국인 수용 → SDB 강함

사회 갈등·양극화 수준 추정

심각성을 일관되게 과장

정권 교체 직후 정치 평가

M2 시점 표류 — 부호 반대 위험

PART 8

마무리

*기억해야 할 핵심 메시지
Q & A*

핵심 정리

두 연구가 함께 그리는 한국 실리콘 샘플링의 풍경

1

한국에서도 실리콘 샘플링은 작동한다

Study 1: 합성 페르소나로 평균 JS 0.132 (강한 일치) — Argyle(2023) 한국 재확인.
Study 2: 응답이력 RAG로 우수 7개에서 평균 KL 0.092 — Demographic 대비 6.6배 개선.

2

다양성을 잃고 한 방향으로 수렴한다

Study 1: 분산 축소 SD비 0.72 + 4가지 편향 (긍정·갈등·SDB·디지털) 식별.
Study 2: 한계 3개 — 시점 표류(M2) · LLM 사전(M3) · 이념 과잉(M4).

3

충실도는 영역이 아니라 분포 형태가 결정

Study 1: 행동·사실 vs 규범·태도 차이 없음. 4.11점 척도 차이 없음.
Study 2: Frontier 영역에서 오히려 RAG 가치 최대 (10.2배 개선).

4

보정의 출발점은 메커니즘 분리에서 시작

두 연구가 공통으로 시사: '쓸 수 있나 없나'가 아니라 '어떻게 보정해 어디까지 쓸까'.
Study 2의 결정 규칙 + Study 1의 편향 메커니즘이 보정 알고리즘의 토대.

마무리하며

"쓸 수 있는가 없는가" → "어떤 보정을 거치면 어디까지 쓸 수 있는가"

STUDY 1 공개 페이지

Nemotron+KSIS 가상 응답자 패널

<https://jonghxxx-persona-survey-nemotron.hf.space>

STUDY 2 공개 페이지

RAPS 시스템 + 3가지 샘플링 방식 데모

<https://jonghxxx-persona-survey.hf.space>

질문과 토론 환영

Q & A

참고문헌

- Aher, G., Arriaga, R. I., & Kalai, A. T. (2023). Using large language models to simulate multiple humans and replicate human subject studies. In *Proceedings of the 40th International Conference on Machine Learning* (Vol. 202, pp. 337–371). PMLR. <https://proceedings.mlr.press/v202/aher23a.html>
- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C., & Wingate, D. (2023). Out of one, many: Using language models to simulate human samples. *Political Analysis*, 31(3), 337–351. <https://doi.org/10.1017/pan.2023.2>
- Bisbee, J., Clinton, J. D., Dorff, C., Kenkel, B., & Larson, J. M. (2024). Synthetic replacements for human survey data? The perils of large language models. *Political Analysis*, 32(4), 401–416. <https://doi.org/10.1017/pan.2024.5>
- Cao, Y., Liu, H., Arora, A., Augenstein, I., Röttger, P., & Hershcovich, D. (2025). Specializing large language models to simulate survey response distributions for global populations. In *Proceedings of the 2025 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*.
- Chapala, S., Mironov, M., & Deng, S. (2025). *Mitigating social desirability bias in random silicon sampling*. [Manuscript submitted for publication]. Eindhoven University of Technology.
- Dillion, D., Tandon, N., Gu, Y., & Gray, K. (2023). Can AI language models replace human participants? *Trends in Cognitive Sciences*, 27(7), 597–600. <https://doi.org/10.1016/j.tics.2023.04.008>
- Geng, M., He, S., & Trotta, R. (2024). *Are large language models chameleons? An attempt to simulate social surveys*. arXiv. <https://arxiv.org/abs/2405.19323>
- Gong, E., Sanders, N. E., & Schneier, B. (2025). *Characterizing the ability of LLMs to recapitulate Americans' distributional responses to public opinion polling questions across political issues*. [Manuscript]. Harvard University.
- Hullman, J., Broska, D., Sun, H., & Shaw, A. (2025). *This human study did not involve human subjects: Validating LLM simulations as behavioral evidence*. [Manuscript]. Northwestern University.
- Krumpal, I. (2013). Determinants of social desirability bias in sensitive surveys: A literature review. *Quality & Quantity*, 47(4), 2025–2047. <https://doi.org/10.1007/s11135-011-9640-9>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- Moon, S., Abdulhai, M., Kang, M., Suh, J., Soedarmadji, W., Behar, E. K., & Chan, D. M. (2024). Virtual personas for language models via an anthology of backstories. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (pp. 19864–19897). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2024.emnlp-main.1110>
- NVIDIA. (2025). *Nemotron-Personas-Korea* [Data set]. Hugging Face. <https://huggingface.co/datasets/nvidia/Nemotron-Personas-Korea>
- Ong, D. C. (2024). GPT-ology, computational models, silicon sampling: How should we think about LLMs in cognitive science? In *Proceedings of the 46th Annual Meeting of the Cognitive Science Society*.
- Park, J. S., Zou, C. Q., Kamphorst, J., Egan, N., Shaw, A., Hill, B. M., Cai, C., Morris, M. R., Liang, P., Willer, R., & Bernstein, M. S. (2024). *LLM agents grounded in self-reports enable general-purpose simulation of individuals*. arXiv. <https://doi.org/10.48550/arXiv.2411.10109>
- Park, S., Moon, J., Kim, S., Cho, W. I., Han, J., Park, J., Song, C., Kim, J., Song, Y., Oh, T., Lee, J., Oh, J., Lyu, S., Jeong, Y., Lee, I., Seo, S., Lee, D., Kim, H., et al. (2021). KLUE: Korean language understanding evaluation. *Advances in Neural Information Processing Systems Datasets and Benchmarks Track*.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing* (pp. 3982–3992).
- Santurkar, S., Durmus, E., Ladhak, F., Lee, C., Liang, P., & Hashimoto, T. (2023). Whose opinions do language models reflect? In *Proceedings of the 40th International Conference on Machine Learning* (Vol. 202, pp. 29971–30004). PMLR. <https://proceedings.mlr.press/v202/santurkar23a.html>
- Sarstedt, M., Adler, S. J., Rau, L., & Schmitt, B. (2024). Using large language models to generate silicon samples in consumer and marketing research: Challenges, opportunities, and guidelines. *Psychology & Marketing*, 41(6), 1254–1270. <https://doi.org/10.1002/mar.22016>
- Sun, S., Lee, E., Nan, D., Zhao, X., Lee, W., Jansen, B. J., & Kim, J. H. (2024). *Random silicon sampling: Simulating human sub-population opinion using a large language model based on group-level demographic information*. arXiv. <https://doi.org/10.48550/arXiv.2402.18144>
- Wihbey, J., & D'Alonzo, S. (2025). *AI simulations of audience attitudes and policy preferences: "Silicon sampling" guidance for communications practitioners* (SSRN Working Paper No. 5533958).